

**2016-2017**

## **Aprendizaje Automático**

### **5. Modelos gráficos**



Francisco Casacuberta Nolla  
(fcn@dsic.upv.es)

Enrique Vidal Ruiz  
(evidal@dsic.upv.es)

Departament de Sistemes Informàtics i Computació (DSIC)  
Universitat Politècnica de València (UPV)

Septiembre, 2016

Aprendizaje Automático. 2016-2017

Modelos gráficos: 5.1

### **Index**

- 1 *Introducción a los modelos gráficos* ▷ 1
- 2 Redes bayesianas ▷ 6
- 3 Independencia condicional ▷ 14
- 4 Inferencia en redes bayesianas ▷ 23
- 5 Campos de Markov aleatorios ▷ 33
- 6 Aprendizaje de modelos gráficos ▷ 40
- 7 Bibliografía y notación ▷ 43

## Modelos gráficos (MG)

- Los MGs y concretamente las redes bayesianas constituyeron la aproximación probabilística a la IA. Uno de los más famosos impulsores fue Judea Pearl ganador del “ACM A.M. Turing Award” en 2011.
- Concepto: Representación compacta de distribuciones de probabilidad conjunta mediante grados dirigidos (**redes bayesianas**) y no dirigidos (**campos aleatorios markovianos**) (teoría de grafos + teoría de la probabilidad). Los MGs generalizan a las redes neuronales y a los modelos de Markov ocultos entre otros.
- Aspectos:
  - **Inferencia**: para responder cuestiones sobre la distribución de probabilidad
  - **Aprendizaje**: para obtener los parámetros y la estructura del modelo gráfico
- Aplicaciones:
  - Diagnóstico médico, de fallos, ...
  - Visión por computador: segmentación de imágenes, reconstrucción 3D, análisis de escenas
  - Procesado del lenguaje natural: reconocimiento del habla, extracción de información textual, traducción automática, ...
  - Robótica: planificación, localización, ...

Septiembre, 2016

DSIC – UPV

*PÁGINA INTENCIONADAMENTE EN BLANCO*

## Algunos conceptos sobre la teoría de las probabilidades

**Probabilidad**  $P(x) : \sum_x P(x) = 1$

**Probabilidad conjunta**  $P(x, y) : \sum_x \sum_y P(x, y) = 1$

**Probabilidad condicional**  $P(x | y) : \sum_x P(x | y) = 1 \quad \forall y$

**Marginales**  $P(x) = \sum_y P(x, y), \quad P(y) = \sum_x P(x, y)$

**Regla de la probabilidad conjunta**  $P(x, y) = P(x) P(y | x)$

**Regla de la cadena**  $P(x_1, x_2, \dots, x_N) = P(x_1) \prod_{i=2}^N P(x_i | x_1, \dots, x_{i-1})$

**Regla de Bayes**  $P(y | x) P(x) = P(y) P(x | y)$

Septiembre, 2016


DSIC – UPV

## Factorización de distribuciones conjuntas

Una distribución conjunta sobre *tres* variables puede expresarse exactamente mediante *seis* factorizaciones completas diferentes:

$$\begin{aligned} P(a, b, c) &= P(a) P(b | a) P(c | a, b) = P(a) P(c | a) P(b | a, c) \\ &= P(b) P(a | b) P(c | a, b) = P(b) P(c | b) P(a | b, c) \\ &= P(c) P(a | c) P(b | a, c) = P(c) P(b | c) P(a | b, c) \end{aligned}$$

Estas factorizaciones se pueden representar mediante grafos dirigidos acíclicos:



Septiembre, 2016

DSIC – UPV

## Index


- 1 Introducción a los modelos gráficos ▷ 1
- 2 *Redes bayesianas* ▷ 6
- 3 Independencia condicional ▷ 14
- 4 Inferencia en redes bayesianas ▷ 23
- 5 Campos de Markov aleatorios ▷ 33
- 6 Aprendizaje de modelos gráficos ▷ 40
- 7 Bibliografía y notación ▷ 43

## Redes bayesianas: ejemplos

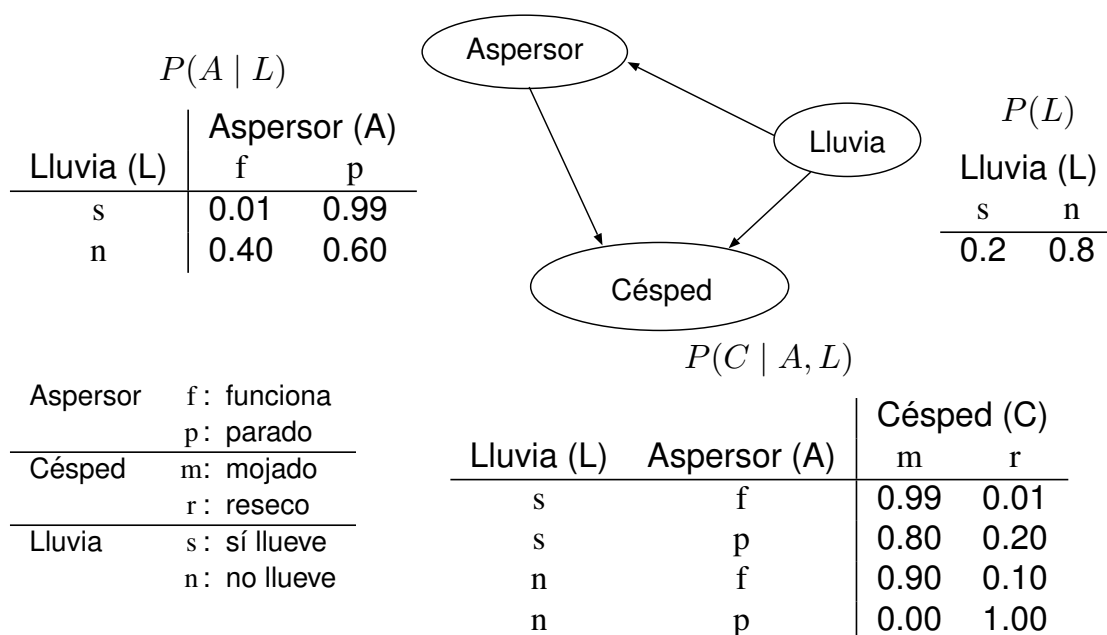
Si hay dependencias inexistentes (o despreciables), la factorización exacta (o aproximada) de una distribución conjunta puede ser incompleta, lo que queda reflejado en el grafo correspondiente. Ejemplos:

$$P(a, b, c) = P(a) P(b) P(c | a, b)$$

$$P(a, b, c, d, e, f) = P(a) P(b) P(c) P(d | b, c) P(e | a, b, d) P(f | a, c)$$



## Redes bayesianas: un ejemplo detallado



Distribución conjunta:  $P(L, A, C) = P(L) P(A | L) P(C | L, A)$

*Ejercicio:* calcular  $P(L = l, A = a, C = c)$ ,  $l \in \{s, n\}$ ,  $a \in \{f, p\}$ ,  $c \in \{m, r\}$ .

Septiembre, 2016

DSIC – UPV

## Un ejemplo detallado (cont.)

- ¿Cuál es la probabilidad de que llueva si el césped está mojado?

$$\begin{aligned}
 P(L = s | C = m) &= \frac{P(L = s, C = m)}{P(C = m)} \\
 &= \frac{\sum_{a \in \{f, p\}} P(L = s, A = a, C = m)}{\sum_{a \in \{f, p\}, l \in \{s, n\}} P(L = l, A = a, C = m)} \\
 &= \frac{0.00198 + 0.1584}{0.00198 + 0.288 + 0.1584 + 0.0} \\
 &= 0.3577
 \end{aligned}$$

- El césped está mojado, ¿llueve?

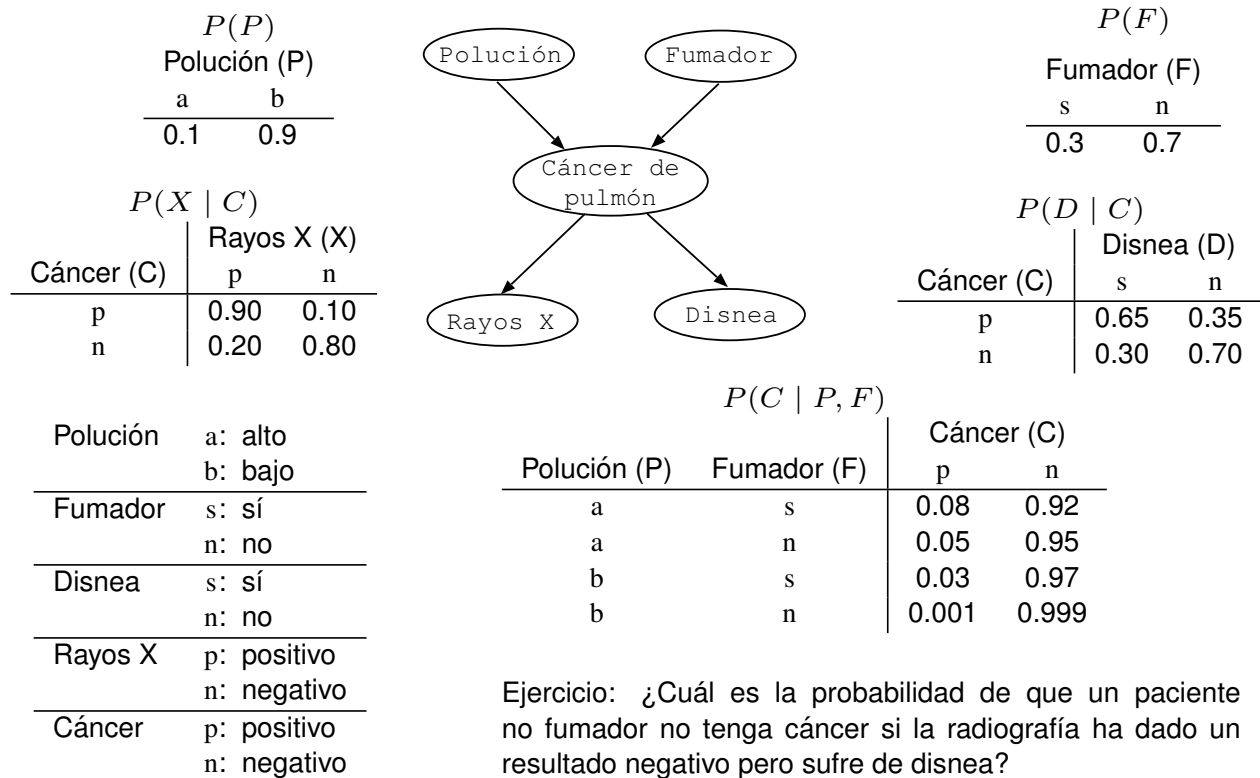
$$\arg \max_{l \in \{s, n\}} P(L = l | C = m) = n$$

*Ejercicio:* a) Calcular  $P(A = a | L = l, C = c)$ ,  $a \in \{p, f\}$ ,  $l \in \{s, n\}$ ,  $c \in \{m, r\}$ .  
b) Llueve y el césped está mojado, ¿cómo está el aspersor?

Septiembre, 2016

DSIC – UPV

## Redes bayesianas: otro ejemplo



Septiembre, 2016

DSIC – UPV

## Redes bayesianas

Una **red bayesiana** es un grafo dirigido y acíclico (“directed acyclic graph” -DAG-) donde:

- Los nodos representan:
  - variables (discretas o continuas)
  - distribuciones de probabilidad condicional para cada variable  $x_i$  dados los valores de las variables asociadas a los nodos padres  $a(x_i)$
- Los arcos representan dependencias entre las variables

Una **red bayesiana** con nodos  $x_1, \dots, x_D$  define una distribución de probabilidad conjunta:


$$P(x_1, \dots, x_D) = \prod_{i=1}^D P(x_i | a(x_i))$$

Septiembre, 2016

DSIC – UPV

## Algunas redes bayesianas simples


- El *clasificador de Bayes* ( $\mathbf{x} \in \mathbb{R}^d$  y  $c \in \{1, \dots, C\}$ ):



$$P(\mathbf{x}, c) = P(c) P(\mathbf{x} | c)$$

$$P(c | \mathbf{x}) = \frac{P(\mathbf{x}, c)}{\sum_c P(\mathbf{x}, c)}$$

- Modelos naive-Bayes* ( $x_i \in \mathbb{R}$  con  $1 \leq i \leq d$  y  $c \in \{1, \dots, C\}$ ):

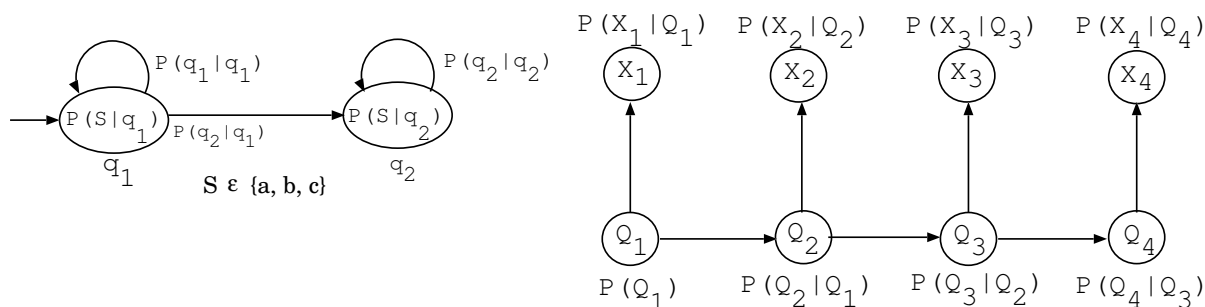


$$P(x_1, \dots, x_d, c) = P(c) \prod_{i=1}^d P(x_i | c)$$

Septiembre, 2016

DSIC – UPV

## Otro ejemplo de red bayesiana: modelo oculto de Markov



$$P(X_1 X_2 X_3 X_4, Q_1 Q_2 Q_3 Q_4) =$$

$$P(Q_1) P(X_1 | Q_1) P(Q_2 | Q_1) P(X_2 | Q_2) P(Q_3 | Q_2) P(X_3 | Q_3) P(Q_4 | Q_3) P(X_4 | Q_4)$$

$$P(X_1 = a, X_2 = a, X_3 = b, X_4 = c) =$$

$$\sum_{r_1, r_2, r_3, r_4 \in \{q_1, q_2\}} P(X_1 = a, X_2 = a, X_3 = b, X_4 = c, Q_1 = r_1, Q_2 = r_2, Q_3 = r_3, Q_4 = r_4)$$

Septiembre, 2016

DSIC – UPV

## Index

- 1 Introducción a los modelos gráficos ▷ 1
- 2 Redes bayesianas ▷ 6
- 3 *Independencia condicional* ▷ 14
- 4 Inferencia en redes bayesianas ▷ 23
- 5 Campos de Markov aleatorios ▷ 33
- 6 Aprendizaje de modelos gráficos ▷ 40
- 7 Bibliografía y notación ▷ 43

## Independencia condicional

Se dice que  $a$  es condicionalmente independiente de  $b$  dado  $c$  (o también que  $a$  está D-separado de  $b$  por  $c$ , y se denota como:  $a \perp\!\!\!\perp b \mid c$ ) si:

$$P(a \mid b, c) = P(a \mid c) \Leftrightarrow P(a, b \mid c) = P(a \mid c)P(b \mid c)$$


Se dice que  $a$  es incondicionalmente independiente de  $b$  (y se denota como:  $a \perp\!\!\!\perp b \mid \emptyset$ ) si:

$$P(a, b) = P(a) P(b)$$



## Independencia in/condicional: estructuras típicas de RBs (I)


- Caso 1: ¿Cuál es la relación entre  $a$  y  $b$ ?



$$P(a, b, c) = P(a)P(c | a)P(b | c)$$

$$P(a, b) = \sum_c P(a)P(c | a)P(b | c)$$

$$\text{En general } P(a, b) \neq P(a)P(b) \Rightarrow a \not\perp b | \emptyset$$




$$\begin{aligned} P(a, b | c) &= \frac{P(a, b, c)}{P(c)} = \frac{P(a)P(c | a)P(b | c)}{P(c)} \\ &= P(a | c)P(b | c) \Rightarrow a \perp b | c \end{aligned}$$

El nodo  $c$  es **cabeza-con-cola** con respecto al camino desde  $a$  a  $b$  via  $c$ : Dos nodos  $a$  y  $b$  conectados via un nodo  $c$  cabeza-con-cola son independientes condicionalmente si  $c$  está dado (nodo  $c$  bloquea al camino desde  $a$  a  $b$ ).

## Independencia in/condicional: estructuras típicas de RBs (II)


- Caso 2: ¿Cuál es la relación entre  $a$  y  $b$ ?



$$P(a, b, c) = P(a | c)P(b | c)P(c)$$

$$P(a, b) = \sum_c P(a | c)P(b | c)P(c)$$

$$\text{En general } P(a, b) \neq P(a)P(b) \Rightarrow a \not\perp b | \emptyset$$




$$P(a, b | c) = \frac{P(a, b, c)}{P(c)} = P(a | c)P(b | c) \Rightarrow a \perp b | c$$

El nodo  $c$  es **cola-con-cola** con respecto a el camino desde  $a$  a  $b$  via  $c$ : Dos nodos  $a$  y  $b$  conectados via un nodo  $c$  cola-con-cola son independientes condicionalmente si  $c$  está dado, (nodo  $c$  bloquea al camino desde  $a$  a  $b$ ).


## Independencia in/condicional: estructuras típicas de RBs (III)

- Caso 3: ¿Cuál es la relación entre  $a$  y  $b$ ?



$$P(a, b, c) = P(a)P(b)P(c | a, b)$$

$$P(a, b) = \sum_c P(a)P(b)P(c | a, b) \\ = P(a)P(b) \Rightarrow a \perp b | \emptyset$$




$$P(a, b | c) = \frac{P(a, b, c)}{P(c)} = \frac{P(a)P(b)P(c | a, b)}{P(c)}$$

$$\text{En general } P(a, b | c) \neq P(a | c)P(b | c) \Rightarrow a \not\perp b | c$$


El nodo  $c$  es to **cabeza-con cabeza** con respecto al camino desde  $a$  a  $b$  via  $c$ : Dos nodos  $a$  y  $b$  conectados via un nodo  $c$  cabeza-con-cabeza no son independientes condicionalmete si  $c$  está dado, pero en caso contrario son independientes incondicionalmente (nodo  $c$  bloquea al camino desde  $a$  a  $b$  cuando  $c$  está dado).

## Independencia condicional: Resumen




Dirección causal  $a \perp b | c$

$$P(a, b | c) = P(a | c)P(b | c)$$



Causa común  $a \perp b | c$

$$P(a, b | c) = P(a | c)P(b | c)$$




Estructura en V  $a \not\perp b | c$

$$\text{En general } P(a, b | c) \neq P(a)P(b)$$

## Independencia condicional: Ejemplo (I)

- $B$  es el estado de la batería (cargada  $B = 1$  o descargada  $B = 0$ )
- $C$  es el estado del depósito de combustible (lleno  $C = 1$  o vacío  $C = 0$ )
- $I$  es el estado del indicador eléctrico del combustible (lleno  $I = 1$  o vacío  $I = 0$ )

$$\begin{aligned}
 P(B = 1) &= P(C = 1) = 0.9 \\
 P(I = 1 \mid B = 1, C = 1) &= 0.8 \\
 P(I = 1 \mid B = 1, C = 0) &= 0.2 \\
 P(I = 1 \mid B = 0, C = 1) &= 0.2 \\
 P(I = 1 \mid B = 0, C = 0) &= 0.1
 \end{aligned}$$



$$P(B, C, I) = P(B) P(C) P(I \mid B, C)$$

Septiembre, 2016

DSIC – UPV


## Independencia condicional: Ejemplo (II)

$B$	$C$	$I$	
		1	0
1	1	0.8	0.2
1	0	0.2	0.8
0	1	0.2	0.8
0	0	0.1	0.9

$B$	
1	0
0.9	0.1

$C$	
1	0
0.9	0.1



$$P(B, C, I) = P(B) P(C) P(I \mid B, C)$$

Si no tenemos información sobre  $I$  ¿cuál es la probabilidad conjunta de  $B$  y  $C$ ?:

$$\begin{aligned}
 P(B, C) &= P(B, C, I=0) + P(B, C, I=1) \\
 &= P(B) P(C) \left( P(I=0 \mid B, C) + P(I=1 \mid B, C) \right) = P(B) P(C) \Rightarrow B \perp\!\!\!\perp C \mid \emptyset
 \end{aligned}$$

Supongamos que vemos  $I = 0$ , ¿Cuál es la probabilidad  $P(B = 0, C = 0 \mid I = 0)$ ?

$$\begin{aligned}
 P(B=0, C=0 \mid I=0) &= \frac{P(B=0) P(C=0) P(I=0 \mid B=0, C=0)}{\sum_{b,c \in \{0,1\}} P(B=b) P(C=c) P(I=0 \mid B=b, C=c)} = 0.02857 \\
 P(B=0 \mid I=0) &= \frac{\sum_{c \in \{0,1\}} P(B=0) P(C=c) P(I=0 \mid B=0, C=c)}{\sum_{b,c \in \{0,1\}} P(B=b) P(C=c) P(I=0 \mid B=b, C=c)} = 0.25714 \\
 P(C=0 \mid I=0) &= \frac{\sum_{b \in \{0,1\}} P(B=b) P(C=0) P(I=0 \mid B=b, C=0)}{\sum_{b,c \in \{0,1\}} P(B=b) P(C=c) P(I=0 \mid B=b, C=c)} = 0.25714
 \end{aligned}$$

$$P(B=0, C=0 \mid I=0) = 0.02857 \neq P(B=0 \mid I=0) P(C=0 \mid I=0) = 0.06612 \Rightarrow B \not\perp\!\!\!\perp C \mid I$$

Septiembre, 2016


DSIC – UPV

## Independencia condicional: Ejemplo (III)

		I	
		1	0
B	C		
1	1	0.8	0.2
1	0	0.2	0.8
0	1	0.2	0.8
0	0	0.1	0.9

B		C	
1	0	1	0
0.9	0.1	0.9	0.1



$$P(B, C, I) = P(B) P(C) P(I | B, C)$$

Supongamos que vemos  $I = 0$ , ¿Cuál es la probabilidad  $P(C = 0 | I = 0)$ ?

$$\begin{aligned}
 P(C = 0 | I = 0) &= \frac{P(I = 0, C = 0)}{P(I = 0)} = \frac{\sum_{B \in \{0,1\}} P(I = 0, C = 0, B)}{\sum_{B \in \{0,1\}} \sum_{C \in \{0,1\}} P(I = 0, C, B)} \\
 &= \frac{\sum_{B \in \{0,1\}} P(I = 0 | B, C = 0) P(B) P(C = 0)}{\sum_{B \in \{0,1\}} \sum_{C \in \{0,1\}} P(I = 0 | B, C) P(B) P(C)} \\
 &= \frac{0.9 \cdot 0.1 \cdot 0.1 + 0.8 \cdot 0.9 \cdot 0.1}{0.315} = 0.25714 > P(C = 0) = 0.1
 \end{aligned}$$

Si ahora vemos  $B = 0$ :  $P(C = 0 | I = 0, B = 0) \approx 0.111 < P(C = 0 | I = 0)$ ,  
es decir,  $C$  depende de  $B$  si se conoce  $I$

Por otra parte, si no conocemos  $I$ :  $P(C = 0 | B = 0) = 0.1 = P(C = 0)$ ,  
es decir,  $C$  no depende de  $B$  si no se conoce  $I$

## Index

- 1 Introducción a los modelos gráficos ▷ 1
- 2 Redes bayesianas ▷ 6
- 3 Independencia condicional ▷ 14
- 4 Inferencia en redes bayesianas ▷ 23
- 5 Campos de Markov aleatorios ▷ 33
- 6 Aprendizaje de modelos gráficos ▷ 40
- 7 Bibliografía y notación ▷ 43

## Inferencia con redes bayesianas

- En general, el problema consiste en calcular la probabilidad a posteriori de alguna variable  $x$  a partir de las distribuciones conjuntas asociadas a una RB, dada alguna evidencia  $e$  (como valores dados de alguna otra variable) y sin importar los valores de resto de las variables  $f$ :

$$P(x | e) = \frac{P(x, e)}{P(e)} \text{ con } P(e) = \sum_{x, f} P(x, e, f) \text{ y } P(x, e) = \sum_f P(x, e, f)$$

- El objetivo es calcular eficientemente  $P(e)$  y  $P(x, e)$
- Por ejemplo: Sea  $P(x_1, x_2, x_3, x_4)$  una distribución conjunta dada por

$$P(x_1, x_2, x_3, x_4) = P(x_2)P(x_1 | x_2)P(x_3 | x_2)P(x_4 | x_3)$$

y se pretende calcular  $P(x_3)$ . Si  $x_i \in X$  para  $i = 1, 2, 3$  verifica que  $|X| = n$

- $P(x_3) = \sum_{x_1, x_2, x_4} P(x_2)P(x_1 | x_2)P(x_3 | x_2)P(x_4 | x_3) \Rightarrow O(n^3)$  operaciones.
- $P(x_3) = \sum_{x_2} P(x_2)P(x_3 | x_2) \sum_{x_1} P(x_1 | x_2) \sum_{x_4} P(x_4 | x_3)$   
 $= \sum_{x_2} P(x_2)P(x_3 | x_2) \Rightarrow O(n)$  operaciones.

Septiembre, 2016

DSIC – UPV

## Inferencia con redes bayesianas

Situaciones donde es útil calcular las probabilidades a-posteriori:


- Predicción: ¿Cuál es la probabilidad de observar un síntoma sabiendo que se tiene una determinada enfermedad?
- Diagnóstico: ¿Cuál es la probabilidad de que una determinada enfermedad sea un diagnóstico correcto dados algunos síntomas?

En RB, la dirección de los enlaces entre variables no restringe el tipo de preguntas que se pueden hacer.

Septiembre, 2016

DSIC – UPV


## Tipos de redes bayesianas



Septiembre, 2016

DSIC – UPV

## Inferencia en una cadena. Propagación de creencias (“Belief propagation”)



Supongamos que el último  $x_i \in E_{x_n}^+$  y el primer  $x_f \in E_{x_n}^-$  están dados:


$$\begin{aligned}
 P(x_n | x_i, x_f) &= \frac{P(x_i, x_f | x_n) P(x_n)}{P(x_i, x_f)} \\
 &= \frac{P(x_i | x_n) P(x_f | x_n) P(x_n)}{P(x_i, x_f)} \quad (\text{Independencia condicional}) \\
 &= \frac{P(x_n | x_i) P(x_i) P(x_f | x_n) P(x_n)}{P(x_n) P(x_i, x_f)} \quad (\text{Regla de Bayes}) \\
 &= \alpha P(x_n | x_i) P(x_f | x_n) \quad (\alpha = P(x_i)/P(x_i, x_f))
 \end{aligned}$$

- Ejercicio: ¿Qué ocurre si también conocemos  $x_{i'} \in E_{x_n}^+$  con  $i' < i$ ?
- Ejercicio: ¿Qué ocurre si también conocemos  $x_{f'} \in E_{x_n}^-$  con  $f' > f$ ?

Septiembre, 2016

DSIC – UPV

## Inferencia en una cadena




$$P(x_n | x_i, x_f) = \alpha P(x_n | x_i) P(x_f | x_n) \stackrel{\text{def}}{=} \alpha \pi(x_n) \lambda(x_n)$$

donde  $\pi(x_n)$  y  $\lambda(x_n)$  se calculan como:

$$\left| \begin{array}{l} \pi(x_i) = 1 \\ \pi(x_n) = \sum_{x_{n-1}} P(x_n | x_{n-1}) \pi(x_{n-1}) \end{array} \right| \quad \left| \begin{array}{l} \lambda(x_f) = 1 \\ \lambda(x_n) = \sum_{x_{n+1}} P(x_{n+1} | x_n) \lambda(x_{n+1}) \end{array} \right|$$


- Ejercicio:  $P(x_n)$

## Inferencia en una cadena (derivación I)



$$\begin{aligned} \pi(x_n) &= P(x_n | x_i) = \sum_{x_{n-1}} P(x_n, x_{n-1} | x_i) \\ &= \sum_{x_{n-1}} P(x_{n-1} | x_i) P(x_n | x_i, x_{n-1}) = \sum_{x_{n-1}} P(x_{n-1} | x_i) P(x_n | x_{n-1}) \\ &= \sum_{x_{n-1}} \pi(x_{n-1}) P(x_n | x_{n-1}) \\ \pi(x_i) &= 1 \end{aligned}$$

## Inferencia en una cadena (derivación II)




$$\begin{aligned}
 \lambda(x_n) &= P(x_f | x_n) = \sum_{x_{n+1}} P(x_f, x_{n+1} | x_n) \\
 &= \sum_{x_{n+1}} P(x_{n+1} | x_n) P(x_f | x_n, x_{n+1}) = \sum_{x_{n+1}} P(x_{n+1} | x_n) P(x_f | x_{n+1}) \\
 &= \sum_{x_{n+1}} P(x_{n+1} | x_n) \lambda(x_{n+1}) \\
 \lambda(x_f) &= 1
 \end{aligned}$$

Septiembre, 2016

DSIC – UPV

## Inferencia en un árbol



Para calcular  $P(x_j | E_{x_j}^+, E_{x_j}^-) = \alpha \pi(x_j) \lambda(x_j)$

$$\lambda(x_j) = \prod_{k=1}^m \lambda_{y_k}(x_j) \text{ con } \lambda_{y_k}(x_j) = \sum_{y_k} \lambda(y_k) P(y_k | x_j)$$

$$\pi(x_j) = \sum_{u_i} P(x_j | u_i) \pi_{x_j}(u_i) \text{ con } \pi_{x_j}(u_i) = \alpha \prod_{j' \neq j} \lambda_{x_{j'}}(u_i) \pi(u_i)$$

Septiembre, 2016

DSIC – UPV



## Inferencia en otros tipos de grafos

- Poli-arboles (“Polytrees”). Los nodos pueden tener múltiples padres, pero solo puede existir un camino único entre cualquier par de nodos: una generalización del algoritmo sobre un árbol.
- Grafos generales. Inferencia aproximada:
  - Métodos variacionales.
  - Métodos basados en el muestreo.

## Index

- 1 Introducción a los modelos gráficos ▷ 1
- 2 Redes bayesianas ▷ 6
- 3 Independencia condicional ▷ 14
- 4 Inferencia en redes bayesianas ▷ 23
- 5 *Campos de Markov aleatorios* ▷ 33
- 6 Aprendizaje de modelos gráficos ▷ 40
- 7 Bibliografía y notación ▷ 43

## Campos de Markov aleatorios

- Aspectos generales:
  - **Independencia condicional** simplificada
  - Asignación compleja de distribuciones de probabilidad.
- Definición de un **campo de Markov aleatorio**
  - Dado un conjunto de variables  $V = \{x_1, \dots, x_D\}$
  - Un grafo no-dirigido  $R = (V, E)$
  - Para un clique  $C$  en  $R$  (un subgrafo completamente conectado),  $V_C$  es el conjunto variables en el clique  $C$ :

$$P(x_1, \dots, x_D) = \frac{1}{Z} \prod_{\forall C \in R} \psi_C(V_C)$$

$\psi_C(V_C)$  es una **función potencial** (estrictamente positiva) y  $Z$  es un factor de normalización (**función de partición**).

## Campos de Markov aleatorios

$$P(x_1, \dots, x_D) = \frac{1}{Z} \prod_{\forall C \in R} \psi_C(V_C)$$

- Las funciones de potencial son de la forma:

$$\psi_C(V_C) = \exp(-E(V_C)),$$

donde  $E(V_C)$  es una función de energía. Por lo tanto,

$$P(x_1, \dots, x_D) = \frac{1}{Z} \exp\left(-\sum_{\forall C \in R} E(V_C)\right)$$

- Un tipo de función de energía interesante es el queda definido mediante funciones lineales generalizadas:



$$E(V_C) = -\sum_k \theta_{C,k} f_{C,k}(V_C)$$

- A partir de una red bayesiana se puede construir un campo de Markov aleatorio

## Un ejemplo

Un conjunto  $x$  de píxeles binarios  
 $x_i \in \{-1, +1\}$ ,  $1 \leq i \leq D$

La imagen está corrupta con probabilidad  
 10% en un conjunto  $y$  de píxeles binarios  
 $y_i \in \{-1, +1\}$ ,  $1 \leq i \leq D$



El objetivo es recuperar la imagen original a partir de la imagen corrupta


Septiembre, 2016

DSIC – UPV

## Un ejemplo

(Bishop. Pattern Recognition and Machine Learning. 2006)

- Fuerte correlación entre  $x_i$  y  $y_i$
- Correlación entre  $x_i$  y  $x_j$  si los dos píxeles son vecinos.



- La función de energía (cliques máximos:  $C_{ij} = (x_i, x_j) \in N(i)$ ,  $C_i = (x_i, y_i) \forall i, j$ ):

$$\left. \begin{array}{l} E(V_{C_{ij}}) = -\beta x_i x_j \\ E(V_{C_i}) = -\nu x_i y_i \end{array} \right\} \rightarrow \sum_{\forall C \in R} E(V_C) = -\beta \sum_{i,j} x_i x_j - \nu \sum_i x_i y_i$$

- La distribución conjunta:

$$P(x_1, \dots, x_D, y_1, \dots, y_D) = \frac{1}{Z} \exp \left( \beta \sum_{i,j} x_i x_j + \nu \sum_i x_i y_i \right)$$

Septiembre, 2016

DSIC – UPV

## Un ejemplo


(Bishop. Pattern Recognition and Machine Learning. 2006)

- A partir de la distribución conjunta:

$$P(x_1, \dots, x_D, y_1, \dots, y_D) = \frac{1}{Z} \exp \left( \beta \sum_{i,j} x_i x_j + \nu \sum_i x_i y_i \right)$$

- el objetivo es:  $(\hat{x}_1, \dots, \hat{x}_D) = \arg \max_{x_1, \dots, x_D} P(x_1, \dots, x_D \mid y_1, \dots, y_D)$

Esto es:



## Inferencia con campos de Markov aleatorios

- En cadenas: Algoritmo adelante-atrás ("Backward-Forward algorithm")
- En árboles: Algoritmo suma-producto
- En grafos generales: Algoritmo de árbol de unión ("Junction tree algorithms"), algoritmo suma-producto ("Loopy belief propagation")

## Index

- 1 Introducción a los modelos gráficos ▷ 1
- 2 Redes bayesianas ▷ 6
- 3 Independencia condicional ▷ 14
- 4 Inferencia en redes bayesianas ▷ 23
- 5 Campos de Markov aleatorios ▷ 33
- 6 *Aprendizaje de modelos gráficos* ▷ 40
- 7 Bibliografía y notación ▷ 43

## Aprendizaje de redes bayesianas

- Dada la estructura, aprender las distribuciones de probabilidad a partir de un conjunto de entrenamiento.
  - Métodos basados en la maximización de la verosimilitud (algoritmo EM -T3-).
  - Aprendizaje bayesiano.
- Aprender la estructura a partir de un conjunto de entrenamiento.
  - Un problema de selección de modelos: búsqueda en el espacio de grafos.

## Algunos toolkits

- BNT  
<https://code.google.com/p/bnt>
- GMTK  
<http://melodi.ee.washington.edu/~bilmes/gmtk/>
- GraphLab  
<http://graphlab.org/toolkits/graphical-models/>
- PMTK3 probabilistic modeling toolkit for Matlab/Octave  
<https://github.com/probml/pmtk>
- Software Packages for Graphical Models  
<http://www.cs.ubc.ca/~murphyk/Software/bnsoft.html>

## Index

- 1 Introducción a los modelos gráficos ▷ 1
- 2 Redes bayesianas ▷ 6
- 3 Independencia condicional ▷ 14
- 4 Inferencia en redes bayesianas ▷ 23
- 5 Campos de Markov aleatorios ▷ 33
- 6 Aprendizaje de modelos gráficos ▷ 40
- 7 *Bibliografía y notación* ▷ 43

## Bibliografía

Christopher M. Bishop: “*Pattern Recognition and Machine Learning*”. Springer, 2006.

## Notación

- $P(x)$ : probabilidad de  $x$
- $P(x, y)$ : probabilidad conjunta de  $x$  e  $y$
- $P(x | y)$ : probabilidad condicional de  $x$  dado  $y$
- Para un conjunto de variables  $V_C$  en un clique  $C$ ,  $\psi_C(V_C) = \exp(-E(V_C))$  es una **función potential** donde  $E(V_C)$  es una función de energía.
- Una función de energía lineal:  $E(V_C) = - \sum_k \theta_{C,k} f_{C,k}(V_C)$  donde  $f_{C,k}$  son determinadas funciones que obtienen características del clique  $C$ .